

## Notas da leitura crítica do artigo “A Few Useful Things to Know About Machine Learning”

- O artigo apresenta 12 lições importantes e de “*folk knowledge*” (conhecimento popular), que investigadores e profissionais, da área de aprendizagem automática aprenderam através da experiência e que são difíceis de encontrar em livros.

- **Learning = Representation + Evaluation + Optimization**

Todos os algoritmos têm 3 componentes: Representation; Evaluation; Optimization.

- Representation: Ou “*hypothesis space*” (espaço de hipóteses). É o conjunto de funções que podem ser aprendidas, se não está no espaço de hipóteses, então não pode ser aprendido.
- Evaluation: “objective function or scoring function”. É uma avaliação, pontua o quão bom é o modelo de aprendizagem automática.
- Optimization: É o método usado para procurar o modelo de aprendizagem automática superior (“*the highest-scoring one*”).

- **It’s Generalization that Counts**

- O objetivo principal da aprendizagem automática é generalizar para além dos exemplos no conjunto de treino. Por mais informação que tenhamos, é improvável que vejamos os mesmos exemplos no momento do teste.

- O algoritmo tem que sair bem em dados não vistos antes, ter uma boa exatidão de treino, pode também significar que o método apenas memorizou os exemplos antes vistos.

Logo, é importante ter dados de testes separados para a avaliação final.

- **Data Alone is Not Enough**

- De acordo com a lição anterior, generalizar é o objetivo, então existe outra grande consequência, que é, dados sozinhos não são suficientes. Logo, todos os aprendizes devem combinar o conhecimento com esses dados para crescer.

- Muitas vezes, os alunos utilizam a dedução e indução, que é uma alavanca de conhecimentos, pois transforma uma pequena quantidade de conhecimento de “input” em grande quantidade de conhecimento “output”.

- **Overfitting Has Many Faces**

- Overfitting: Se o conhecimento e os dados que temos não são suficientes para classificar corretamente o classificador, então estamos simplesmente a codificar peculiaridades aleatórias nos dados e não a realidade.

Uma das maneiras de interpretar “Overfitting” é partir o erro de generalização em duas componentes:

- Bias: Tendência de o aluno aprender constantemente a mesma coisa errada.
- Variance: Tendência de o aluno aprender coisas aleatórias independentemente da realidade.

Algumas ferramentas contra o “Overfitting”:

- Suposições falsas fortes podem ser melhores do que as verdadeiras fracas (pois com a última o aluno precisa de mais dados para evitar o “overfitting”).
- A validação cruzada (“*Cross-validation*”).
- Prazo de regularização para avaliação da função. (“*regularization term*”).

- **Intuition Fails in High Dimensions**

- Depois do “Overfitting”, um dos problemas na aprendizagem automática é a maldição da dimensionalidade (“*curse of dimensionality*”), ou seja, refere que muitos algoritmos que funcionam bem em baixas dimensões se tornam inacessíveis em altas dimensões, o mesmo acontece com a generalização, torna-se mais difícil à medida que o número de características dos exemplos aumenta.
- As nossas intuições, vêm de um mundo tridimensional, muitas vezes não se aplicam em mundos de alta dimensionalidade.
- Existe um método que neutraliza esta “maldição”, denominado de “*blessing of nonuniformity*”

- **Theoretical Guarantees Are Not What They Seem**

- A aprendizagem automática está cheia de garantias teóricas.
- O tipo mais comum é um limite para o número de exemplos necessários para garantir uma boa generalização do modelo. Além disso, também diz que dada uma grande quantidade de dados de treinamento, o nosso algoritmo retornaria uma boa hipótese com alta probabilidade ou não encontrar uma hipótese consistente, ou seja, não nos diz sobre como selecionar um bom espaço de hipóteses.
- Outro tipo é o limite assintótico (“*asymptotic*”), que dado um número infinito de dados, o algoritmo garante produzir um classificador correto, sendo que na prática não temos dados infinitos.
- Em suma, as garantias teóricas não devem ser usadas como único critério para selecionar um algoritmo.

- **Feature Engineering Is The Key**

- A aprendizagem automática é um processo iterativo de executar o modelo, analisar os resultados, modificar os dados e/ ou o modelo. E repetir.

- A engenharia de características é um passo crucial na aprendizagem automática, pois é um fator importante para decidir quais os projetos que têm sucesso. Ou seja, ter o tipo certo de características (independentes que se correlacionam bem com a classe) torna a aprendizagem mais fácil. No entanto, a engenharia de características também é difícil, uma vez que requer conhecimento específico do domínio, que se estende para além dos dados que temos.

- Características que parecem irrelevantes isoladas, podem ser relevante em combinação.

- **More Data Beats a Cleverer Algorithm**

- Como regra geral, um algoritmo simples / menos inteligente com muitos dados é mais eficaz do que um algoritmo inteligente com uma quantidade modesta de dados. Porém, quanto mais dados, maior é a quantidade de problemas.

- São usados classificadores mais simples, porque os complexos levam muito tempo para aprender. Parte da solução é encontrar maneiras rápidas de aprender classificadores complexos. (*"simpler classifiers wind up being used"*).

- Os alunos com tamanho fixo (*"parametric ones"*) podem aproveitar os dados apenas até certo ponto, pois se adicionar mais dados não melhora os resultados. Os alunos com tamanho variável (*"nonparametric learners"*) podem, teoricamente, aprender qualquer função com quantidade suficiente de dados, apesar de também serem limitados pelas limitações do algoritmo.

- **Learn Many Models, Not Just One**

- Hoje em dia, o foco está em combinar as diversas variantes de diferentes algoritmos, de modo a obter os melhores resultados (*"we combine many variations, the results are better, often much better"*). Técnicas de ensemblagem de modelos (*"model ensembles"*): bagging, boosting e stacking.

- **Simplicity Does Not Imply Accuracy**

- Na aprendizagem automática, de acordo com a declaração de Occam's, dois classificadores com o mesmo erro de treino, o mais simples dos dois provavelmente terá o menor erro de teste. Mas, na verdade, há muitos contraexemplos para isso, como, por exemplo, o teorema *"no free lunch"*.

- A conclusão é que hipóteses mais simples devem ser preferidas porque a simplicidade é uma virtude em si mesma, não por causa de uma conexão hipotética com a precisão.

- **Representable Does Not Imply Learnable**

- Só porque uma função pode ser representada, não significa que a função possa realmente ser aprendida. Restrições impostas pelos dados, tempo e memória limitam as funções que podem ser efetivamente aprendidas.

- Um exemplo, é os alunos de árvores de decisão não podem aprender árvores com mais folhas do que o número de pontos de dados de treino.
- A verdadeira pergunta a se fazer é "Se uma função pode ser aprendida?" e não "Se uma função pode ser representada?".
- Encontrar métodos para aprender representações mais profundas é uma das principais fronteiras de pesquisa em aprendizagem de máquina.

- **Correlation Does Not Imply Causation**

- A correlação não implica causalidade, de acordo com o autor. Mas, alguns alunos que só podem aprender correlações têm os seus resultados tratados como representando relações causais.
- A aprendizagem de máquina/ automática é usada para identificar correlações para orientar ações.
- A aprendizagem de máquina é normalmente aplicada a dados observacionais, onde as variáveis preditivas não estão sob o controle do aluno. Alguns algoritmos podem extrair informações causais, mas a sua aplicabilidade é limitada, de acordo com o autor.
- Será que as relações causais podem ser usadas para melhorar os modelos do aluno, especialmente em termos de aumentar a eficácia das ações baseadas em modelos de previsão?

Por último, concordo com a conclusão do autor, pois a aprendizagem de máquina apesar de ser difícil de encontrar, é crucial para o sucesso de cada um e este é um bom artigo para começar, graças às suas definições úteis.

Trabalho realizado por: Luís Gonçalo Carvalho Nº51817